

26년도 4월호 월간 데이콘

스마트 창고 출고 지연 예측 솔루션

AMR 로봇 기반 창고의 출고 지연 예측 모델 개발

TEAM jiwonyyy

문제 정의

스마트 창고 환경에서 실시간 운영 데이터를 기반으로
향후 30분간 평균 출고 지연 시간을 예측하는 AI 모델 개발

1 데이터

train 250,000행
test 50,000행
10,000개 시나리오 × 25 타임슬롯,
layout_info 레이아웃 정보 포함

2 타겟 변수


avg_delay_minutes_next_30m,
평균 18~19분, 최대 715분,
Fold 2.5에 극단 시나리오 집중

3 평가 지표

MAE(Mean Absolute Error)

Public/Private 분리 평가

파이프라인



피처 엔지니어링

시나리오 집계

26개 원본 피처 × (mean/max/min/std)
= 104개 집계 피처 생성

- **battery_cong_interaction** — feature importance 1위 (16%)
- **bottle_neck_scen_mean** — 2위 (7.8%)
- **pack_utilization_scen_mean** — 3위 (6.7%)

Rolling & Lag

- window 3·5·10 rolling mean·std
- EWM (alpha=0.3) — order_inflow, congestion, pack_utilization
- lag 1·2·3 + diff1·diff2
- order_per_station_roll5_mean 상위권

상호작용 & 기타

- scen_mean 간 곱: 6종 상호작용 피처 (cong_pack, battery_cong 등)
- rel_to_scen: 현재값 / 시나리오 평균
- ts_sin/ts_cos: 타임슬롯 순환 인코딩
- sqrt_order_inflow, row_frac_in_scen


AutoEncoder - 잠재 피쳐 추출

구조: Input(~300개) → Hidden(256) → Latent(32차원) →
Hidden(256) → Reconstruction Output

작동 방식

MSE 재구성 손실로 피쳐 간 비선형 관계를 압축 학습
Fold별 학습 → 5개 fold 잠재 벡터 평균으로 test
인코딩 (Data Leak 방지)

32차원 ae_z0 ~ ae_z31을 Stage 1 피쳐에 추가
Early Stopping (patience=5) +
StandardScaler 정규화 적용



핵심 아이디어 & 2- Stage Pipeline



"모델이 이전 시점에 얼마나 지연될 거라고 예측했는지"를 피처로 사용하면
시계열 연속성을 더 잘 반영할 수 있다.

Stage 1 — 기본 피처 학습

모델: LGB×2 seeds + XGB + CAT

Early stopping: 500 rounds

Sample Weight 적용 (고지연 ×1.25, 엣지 슬롯 ×1.10)

5-Fold StratifiedGroupKFold

출력: OOF 예측값 → Stage 2 입력으로 전달

Stage 2 — Pred-lag 재학습

추가 피처 9개:

pred_lag1/2/3, pred_diff1/2,
pred_roll3_mean, pred_roll5_mean,
pred_ewm3, pred_lag1_log
LGB/XGB/CAT 동일 구조로 재학습

S1 ↔ S2 blend alpha 자동 탐색 (step=0.01)

2- Stage Pipeline - Optuna

[Optuna 탐색 파라미터 — 8개]

Optuna HPO (LightGBM)

- 20 trials, TPESampler(seed=42)
- 학습 데이터 40% 샘플로 빠른 탐색
- 탐색 범위: learning_rate, num_leaves, min_child_samples, reg_lambda 등 8개 파라미터
- 최적 파라미터 → LGB / XGB / CAT 공통 적용

파라미터 탐색

learning_rate 0.005 ~ 0.03
max_depth 5 ~ 12
num_leaves 63 ~ 2047
min_child_samples 20 ~ 100
subsample 0.6 ~ 0.9
colsample_bytree 0.3 ~ 0.8
reg_alpha 0.0 ~ 1.0
reg_lambda 0.5 ~ 10.0

탐색 횟수: 20 trials
샘플 비율: 전체의 40%

재현성 & Seed 고정

실험 재현성 확보를 위해 제출 코드에는 Seed 값을 하이퍼파라미터로 고정

구성요소별 Seed 고정

구성요소설정

K-Foldrandom_state = 42

OptunaTPESampler(seed = 42)

LGB / XGB / CATrandom_state = 42

AutoEncodermanual_seed(42 + fold)

리더보드 제출 시점

Optuna seed 미고정 상태로 제출

→ 탐색 경로가 랜덤하여
매 실행마다 결과 상이

코드 제출 시점

Private Score 복원을 위해 Seed 값 고정

→ 전 구성요소 seed=42 고정
→ 동일 환경에서 재현 가능

앙상블 & 후처리

Ensemble

Power-weighted Ensemble

성능 좋은 모델에 더 높은 가중치 자동 부여

LGB / XGB / CAT 7가지 조합 중 OOF MAE 최저 선택

S1 $\leftrightarrow$ S2 Blending

최종 = $\alpha \times S1 + (1-\alpha) \times S2$

α 를 0~1 범위에서 자동 탐색

타임슬롯별 최적 α 개별 적용 $\rightarrow$ 20% 글로벌 스무딩

후처리

Global Calibration

Scale — 전체적으로 크기 조정

예측값이 전반적으로 높거나 낮을 때 비율로 보정

Bias — 전체적으로 값 이동

예측값에 일정한 상수를 더하거나 빼서 보정

Clip — 극단값 제거


세 파라미터 조합을 탐색해서 OOF MAE가 개선될 때만 적용

교차 검증 전략

StratifiedGroupKFold (5-fold, shuffle=True, seed=42)

시나리오별 타겟 평균을 10분위로 나눠 각 fold에 지연 분포를 균등 배분 → Fold별 타겟 평균 편차 최소화 목적

Fold별 OOF MAE 분포 (LightGBM 기준)



Fold 2·5가 튀는 원인

- congestion_score 평균이 양호 fold 대비 +3~4% 높음
- 극단 시나리오(평균 지연 200분↑) 집중 배치

대응 방법

- StratifiedGroupKFold로 편차 최소화
- Sample Weight로 고지연 샘플 강조
- Global Calibration으로 스케일 보정

결과 & 결론

9.71506

OOF MAE: 8.458
Public Score

9.95639

Private Score

8위

Final Ranking

핵심 기여 요소

시나리오 집계 피쳐 — congestion_score_scen_mean 단독 30% 기여

2-Stage Pipeline — Pred-lag 피쳐로 시계열 연속성 반영


AutoEncoder — 237개 피쳐를 32차원 잠재 표현으로 압축

Power-weighted Ensemble — OOF 기반 최적 조합 자동 탐색

Global Calibration — scale/bias/clip 자동 보정


한계점 & 향후 개선 방향

한계점



OOF-LB 갭 (1.27)

OOF MAE 8.46 → Public 9.72로 괴리 발생
시나리오 집계 피쳐(scen_mean/max/min)
가 훈련 시나리오에 과적합



일반화 불확실성

AutoEncoder가 훈련 시나리오 분포를 학습
→ 미관측 시나리오에서 임베딩 품질 저하 가능

개선 방향



모델 정규화 강화

min_child_samples 상향, reg_lambda 강화
LGB path_smooth 파라미터 추가



검증 전략 개선

N_Folds 5 → 7로 증가 → CV 안정성 향상



AutoEncoder 개선

Dropout 추가 (0.0 → 0.2)
Latent dim 축소 (32 → 16~24)

모델 별 하이퍼파라미터

LightGBM

파라미터	Stage 1	Stage 2
n_estimators	25,000	12,000
learning_rate	0.01 *	0.02
num_leaves	2,047 *	511
min_child_samples	60 *	80
subsample	0.75 *	0.8
reg_lambda	5.0 *	4.0
early_stopping	300	120

XGBoost

파라미터	Stage 1	Stage 2
n_estimators	20,000	8,000
learning_rate	0.012 *	0.02
max_depth	10 *	6
subsample	0.75 *	0.8
reg_lambda	5.0 *	2.5
early_stopping	500	120

CatBoost

파라미터	Stage 1	Stage 2
iterations	20,000	8,000
learning_rate	0.012 *	0.02
depth	10 *	6
l2_leaf_reg	5.0	4.0
subsample	0.75 *	0.8
early_stopping	500	120

재현 환경

OS	Windows 11
Python	3.11.3
LightGBM	4.3.0
XGBoost	2.0.3
CatBoost	1.2.5

Optuna	3.6.1
NumPy	1.26.4
Pandas	2.2.2